

蔬菜类商品的自动定价与补货决策

摘要

针对蔬菜类商品高损耗、短保质期与需求不确定性并存的运营特征，本文基于某商超 2020 年 7 月至 2023 年 6 月的 878,503 条销售流水、55,982 条批发价格记录及各单品损耗率数据，构建了“多尺度依赖分析—联合定价库存随机优化—混合整数规划品种选择—信息价值评估”四阶段集成优化框架，自底向上、逐层递进地依次解决品类需求规律刻画、品类级定价与补货、单品级品种选择以及数据价值评估四个问题。

针对问题一，刻画需求的多尺度结构与品类间关系。综合运用 STL 时序分解与 MODWT (db4) 小波多分辨率分析，从趋势、季节、残差及多时间尺度揭示 6 大蔬菜品类的销量演化规律，发现花叶类的季节性方差占比最高 (41.12%)、水生根茎类的变异系数最大 ($CV=0.848$)；通过 student-t Copula 建模品类间尾部依赖，识别出花叶类-花菜类 ($Kendall\tau=0.457$) 与食用菌-水生根茎类 ($\tau=0.435$) 为最强正向联动；进而构建 Granger 因果网络，发现 30 组有向配对中有 26 组 (86.7%) 显著，且茄类是典型的“需求跟随者”。在单品层面，三年累计销量呈长尾分布 (基尼系数 0.793，前 20% 单品贡献 84.4% 的销量)，为问题三的品种选择提供了直接依据。

针对问题二，建立联合定价-库存随机优化模型。针对销售数据中价格与需求的同时性内生问题，以批发价格为工具变量、采用两阶段最小二乘法 (2SLS) 估计无偏价格弹性；以 SARIMAX 预测未来七日各品类需求 (MAPE 介于 21.2%–77.9%)；在含加价率约束的报童模型下，由 KKT 条件联立求解最优定价与订货量，得到六大品类七日最优方案 (如花叶类 $p^*=19.36$ 元/kg、 $Q^*=133.67$ kg)，七日总期望利润 18,319.8 元、日均约 2617.11 元，并以 Wasserstein 分布鲁棒优化 (DRO) 检验解的稳健性。

针对问题三，将决策粒度从品类细化到单品。构建混合整数线性规划 (MILP) 模型，在品种数量约束 (27–33 种)、最小陈列量约束 (2.5kg) 与品类全覆盖约束下，将品种选择 (0-1 变量)、补货量与定价整合到统一框架求解，从 49 种可选单品中最优选出 30 种，总补货量 222.6kg、总期望利润 296.4 元；灵敏度分析表明利润对损耗率与最小陈列量约束高度敏感。

针对问题四，以 EVPI (完美信息期望价值) 与 EVSI (样本信息期望价值) 量化附加数据的经济价值：花叶类的 EVPI 最高 (88.95 元/天)，六大品类合计 303.75 元/天，据此给出数据采购优先级为天气预报 > 客流监控 > 竞品价格。模型检验显示，SARIMAX 残差未通过 Ljung-Box 白噪声检验 ($p<0.001$)，存在显著自相关与右侧重尾，印证了以对数正态分布建模需求的合理性；灵敏度分析进一步验证了最优解对损耗率与需求方差扰动的鲁棒性。

关键词：蔬菜定价；报童模型；Copula 依赖结构；混合整数规划；随机优化；小波分析

一、问题重述

某超市经营蔬菜类商品，涉及花叶类、辣椒类、食用菌、花菜类、水生根茎类和茄类共 6 个品类、251 种单品。现有 2020 年 7 月 1 日至 2023 年 6 月 30 日期间的销售流水数据（共 878,503 条记录）、蔬菜批发价格数据（55,982 条记录）以及各品类的损耗率信息。蔬菜类商品因其生鲜易腐的特性，在采购、定价和库存管理上面临独特的挑战：补货量过多会导致大量损耗浪费，补货量不足则会造成缺货损失和顾客流失。同时，蔬菜的市场价格受到季节性供给、批发市场行情和消费者偏好等多重因素的共同作用。

本文需要解决以下四个问题：

问题一要求分析各蔬菜品类的销售分布规律以及单品或品类之间的相互关系；

问题二要求在品类层面制定 2023 年 7 月 1 日至 7 日的每日补货量和定价策略；

问题三进一步细化到单品层面，在满足品种数量约束（27 至 33 种）和最小陈列量约束（不低于 2.5 千克）的条件下，确定最优品种选择、补货量和定价方案；

问题四则要求分析是否需要引入额外的数据来优化决策。

二、问题分析

本文面对的核心挑战在于蔬菜类商品的需求不确定性、品类间的复杂依赖关系以及定价与补货决策之间的相互耦合。为了系统性地解决上述四个问题，本文设计了一个自底向上、逐层递进的四阶段建模框架，如下图所示：




图 1 全篇思路框架图

针对问题一，本文从数据驱动的角度出发，对 6 大蔬菜品类的销量时间序列进行多尺度分析。具体而言，首先利用 STL 分解提取趋势、季节和残差成分，揭示各品类销量的宏观演化规律和周期性特征；然后通过小波变换在不同时间分辨率下捕捉销量波动的频域结构；再利用 Copula 函数建模品类间销量的联合分布和尾部依赖关系；最

后借助 *Granger* 因果检验和互信息分析构建品类间的因果网络和信息流拓扑。这一阶段为后续的需求预测和优化决策提供了坚实的统计基础和关键输入参数。

针对问题二，本文将定价决策与库存决策纳入统一的随机优化框架。由于销售数据中价格与需求的同时性偏误，本文采用 2SLS 方法，以批发价格作为工具变量来识别因果性的价格弹性。在获得无偏弹性估计后，构建以期望利润最大化为目标的含加价率约束的报童模型，利用 KKT 条件推导出最优定价与订货量的解析解或数值求解方案，并通过鲁棒性检验确保解的稳定性。

针对问题三，本文将问题进一步拓展到单品层面的品种选择。构建 MILP 模型将品种选择（二元决策变量）、补货量（连续变量）和定价（基于弹性的线性化近似）整合到同一个优化模型中，并施加品种数量约束、最小陈列量约束和品类覆盖约束，利用分支定界法求解全局最优。

最后，本文引入决策理论中的信息价值框架（EVPI 和 EVSI），定量分析引入额外数据（如精准天气预报、客流监控和竞品价格）对优化决策的边际价值，从而为超市的数据采购决策提供经济学依据。

三、模型假设与符号说明

3.1 基本假设

在模型构建过程中，本文做出以下合理假设。第一，假设每日的补货决策在当日营业开始前完成，补货量一次到位，日内不进行二次补货。第二，蔬菜当日未售出的部分按各品类的固定损耗率计算损耗成本，不考虑打折销售和次日转售的情形。第三，消费者的需求仅受价格和季节性因素影响，不考虑促销活动、竞争对手行为等外部冲击。第四，批发价格为外生变量，超市为价格接受者，批发价格不受超市采购量的影响。第五，不同蔬菜品类的需求可以存在统计上的相关性，但各品类的定价决策对其他品类需求的交叉影响在短期内可忽略。

3.2 符号说明

本文所用的主要符号定义如表 1 所示。

表 1 主要符号说明

符号	含义
$D_i(t)$	第 i 品类在第 t 天的随机需求量 (千克)
$p_i(t)$	第 i 品类在第 t 天的零售定价 (元/千克)
$Q_i(t)$	第 i 品类在第 t 天的补货量 (千克)
$c_i(t)$	第 i 品类在第 t 天的批发成本 (元/千克)
α_i	第 i 品类的损耗率
ε_i	第 i 品类的价格弹性系数 (2SLS 估计)
A_i	第 i 品类的需求规模参数 (由历史数据标定)
$r_{\min}$	最低加价率约束
y_j	第 j 种单品的选择决策变量 ($\{0,1\}$ 变量)
$\pi(\cdot)$	期望利润函数
$FD(\cdot), fD(\cdot)$	需求的累积分布函数与概率密度函数
$C(\cdot)$	Copula 函数
τ	Kendall 秩相关系数
D	Student-t Copula 的自由度参数
Σ	Copula 相关矩阵
λ_U, λ_L	上尾、下尾依赖系数
a, b	小波变换的尺度参数与平移参数
$\psi(\cdot)$	母小波函数
$W(a, b)$	小波系数 (时频平面的变换结果)
M	大 M 约束中的充分大正数
c_i	第 i 个品类所含单品的编号集合
P	由历史数据估计的经验需求分布
E	分布鲁棒优化中的 Wasserstein 模糊半径
$MI(X, Y)$	随机变量 X 与 Y 之间的互信息
$W_1(\cdot, \cdot)$	一阶 Wasserstein 距离

四、模型建立与求解

4.1 多尺度依赖分析模型

4.1.1 STL 时序分解

为了从宏观层面揭示蔬菜品类销量的时序结构特征，本文首先对六大品类的日销量序列进行 STL 分解。STL 方法将时间序列 $Y(t)$ 分解为三个不可直接观测的组分：

$$Y(t)=T(t)+S(t)+R(t) \tag{1}$$

其中 $T(t)$ 为趋势成分，反映销量的长期走势和结构性变化； $S(t)$ 为季节成分，刻画以周或年为周期的规律性波动； $R(t)$ 为残差成分，包含不可预测的随机扰动和异常事件的影响。STL 的核心在于通过 LOESS（局部加权回归散点平滑法）进行迭代拟合：在外循环中利用鲁棒权重降低异常值对趋势估计的影响，在内循环中交替提取季节成分和趋势成分。本文将季节周期设为 7 天（对应周效应），趋势平滑窗口取为 365 天以捕捉年度趋势，季节平滑窗口取为 15 以保证季节模式的稳定提取。

如图 2 所示，STL 分解结果清晰地展现了各品类销量的时序结构差异。花叶类作为销量最大的品类（日均 181.3 千克），呈现出明显的年度周期性，夏季销量显著高于冬季；辣椒类和食用菌的销量在三年间存在一定的上升趋势；而茄类和花菜类则表现出较强的季节集中性，在非当季月份销量急剧下降。




图 2 六大蔬菜品类 STL 时序分解结果

为了定量比较各品类的时序结构特征，本文计算了各组分量方差占总方差的比例以及销量的描述性统计量，结果分别如表 2 和表 3 所示

表 2 各品类日销量描述性统计

品类	日均销量(kg)	标准差(kg)	变异系数(CV)
花叶类	181.30	87.55	0.483
辣椒类	83.64	53.79	0.643
食用菌	69.49	48.73	0.701
花菜类	38.14	22.89	0.600
水生根茎类	37.06	31.42	0.848
茄类	20.49	13.57	0.662

从表 2 可以看出，六大品类的销量规模差异显著，花叶类的日均销量是茄类的 8.8 倍。变异系数（CV）从高到低依次为水生根茎类（0.848）、食用菌（0.701）、茄类（0.662）、辣椒类（0.643）、花菜类（0.600）和花叶类（0.483），表明水生根茎类的需求波动性最大，而花叶类作为基础叶菜，需求相对平稳。变异系数的高低直接决定了安全库存水平的设定：高 CV 品类需要更高的安全库存以应对需求不确定性，但同时也面临更大的损耗风险。

表 3 STL 分解各组分方差占比（%）

品类	趋势方差占比	季节方差占比	残差方差占比
花叶类	36	41.12	33
辣椒类	49	11	40
食用菌	42	18	40
花菜类	45	22	33
水生根茎类	38	19	43
茄类	41	15	44

表 3 的结果揭示了一个值得关注的模式：花叶类的季节性方差占比高达 41.12%，远超其他品类，说明花叶类销量受季节因素的驱动最为显著，这与叶菜类蔬菜在夏季生长旺盛、供应充足且消费者偏好增强的实际情况一致。相比之下，辣椒类和茄类的趋势方差占比较高（分别为 49%和 41%），表明其销量更多受到长期结构性因素（如消费习惯变迁）的影响。残差方差占比在 33%至 44%之间，说明各品类均存在相当程度的不可预测波动，这进一步证实了采用随机优化方法的必要性。

4.1.2 小波多分辨率分析

模型选择依据：STL 提取的是固定频率（7 天）的季节成分，但蔬菜销量同时受到多个时间尺度（日波动、月度促销周期、年度气候周期）的驱动，这些不同尺度的波动在 STL 残差中被混同为“噪声”。小波多分辨率分析能够将信号分解到时域和频域，识别不同尺度上的波动能量分布和局部瞬态特征，从而为后续的需求预测和库存安全库存设定提供更丰富的先验信息。这是 STL 与小波分析在方法论上互补而非重复的内在逻辑^[1]。

STL 分解虽然有效地分离了趋势和固定周期成分，但难以捕捉非平稳信号中的多尺度瞬态特征。为此，本文进一步采用最大重叠离散小波变换（MODWT，db4 小波）对销量序列进行多分辨率分析。小波变换将时间序列 $Y(t)$ 映射到时频平面：

$$W(a, b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{+\infty} Y(t) \psi^* \left(\frac{t-b}{a} \right) dt \quad (2)$$

其中 $a > 0$ 为尺度参数（对应频率的倒数）， b 为平移参数， ψ^* 为母小波函数的复共轭。本文采用 Daubechiesdb4 小波作为分析小波，因其优良的时频局部化特性，特别适用于分析销量序列中的周期性波动和突变特征。

如为刻画销量波动在不同时间分辨率下的频域结构，对去均值序列作最大重叠离散小波变换（MODWT,db4 小波），分解为高频细节 $D1-D5$ 与低频趋势 $A5$ ，各尺度方差贡献率如图 3。结果显示：短期突发尺度（ $D1$ ，2-4 天）：所有品类在此频段均存在不可忽视的波动能量，其中花叶类占比最高（21.0%）。这在业务逻辑上极具解释力：花叶类极易受短期天气剧变或物流延误的冲击，呈现出强烈的短期高频震荡特征。

中短期过渡尺度（ $D2-D4$ ，4-32 天）：能量分布较为均匀且占比呈阶梯状递减，反映了以周或半月为单位的常规采购周期带来的温和波动。

长期趋势尺度（ $A4$ ，长期趋势）：长周期能量主导了所有品类的总体波动（贡献率均在 40% 以上）。其中，茄类（51.6%）和水生根茎类（47.2%）的长周期方差贡献最为突出。这印证了这两类蔬菜的销量主要受农作物的宏观上市季节和长期饮食结构演变驱动，抗短期干扰能力较强。

小波分析的结果与 STL 分解相互印证。这种跨尺度的能量测算为后续的库存安全边界设定提供了精准指导：对于 $D1$ 能量极高的花叶类，必须在报童模型中设定更敏捷的安全库存以应对短期冲击；而对于 $A4$ 主导的茄类，库存优化的重心则应放在精准的长期宏观趋势预测上。




图 3 六品类小波功率谱多尺度分析

小波分析的结果与 STL 分解相互补充、互为印证。STL 提供了确定性的组分分解，而小波变换则从频域视角揭示了各品类销量波动的跨尺度能量传递特征。两种方法的结合使本文能够全面理解蔬菜品类需求的时序结构特征，为后续的需求分布参数估计提供了更为精准的输入。

4.1.3 Copula 依赖结构分析

模型选择依据：蔬菜销量数据高度右偏（偏度 2.5–3.1），品类间的联动不仅体现在均值层面，更体现在极端需求的同步发生（尾部依赖）。Copula 方法的核心优势在于：（1）将联合分布分解为各边缘分布与相关结构，无须对边缘分布做正态性假设；（2）Student-tCopula 能显式建模上下尾部依赖系数（ λ_U 、 λ_L ），适合描述极端需求联动；（3）Kendall's τ 基于秩次，对数据偏态和极端值鲁棒。本文对 15 组品类配对分别拟合 Gaussian Copula、Student-t Copula 和 Clayton Copula 三族，以 AIC 准则确定每对最优 Copula 族^[2]。

蔬菜品类之间的销量并非相互独立，而是存在复杂的联合分布和尾部依赖关系^[3]。例如，当极端天气导致某一品类供应紧张时，消费者可能转向替代品类，形成负向的尾部依赖；而节假日效应则可能同时推高多个品类的需求，产生正向的尾部依赖。为了精确刻画这种非线性、非对称的依赖结构，本文采用 Copula 函数进行建模。

根据 Sklar 定理，任意一个多维联合分布函数 $F(x_1, x_2, \dots, x_n)$ 都可以表示为各边缘分布 $F_i(X_i)$ 和一个 Copula 函数 C 的组合：

$$F(x_1, x_2, \dots, x_n) = C(F_1(x_1), F_2(x_2), \dots, F_n(x_n)) \quad (3)$$

本文考虑三种常用的椭圆族和阿基米德族 Copula：

Gaussian Copula、Student-t Copula 和 Clayton Copula。其中 Student-t Copula 的密度函数为：

$$c_{v,\Sigma}(u_1, u_2) = \frac{f_{v,\Sigma}(t_v^{-1}(u_1), t_v^{-1}(u_2))}{f_v(t_v^{-1}(u_1)) \cdot f_v(t_v^{-1}(u_2))} \quad (4)$$

其中 $t^{D,1}$ 为自由度为 D 的 t 分布的分位数函数， $f_{D,\Sigma}$ 为二维 t 分布的密度

函数， Σ 为相关矩阵。Student-tCopula 相对于 GaussianCopula 的优势在于其能够捕捉尾部依赖——即极端事件的同步发生概率。




图 4 代表性品类配对的 Copula 秩散点图 (4 组典型配对)

如图 4 所示，为直观展示品类间秩相关结构，本文从 15 组配对中选取 4 组具有代表性的配对（花叶类-辣椒类、花叶类-花菜类、花叶类-食用菌、水生根茎类-食用菌），绘制经验秩散点图。图中每个点的横纵坐标分别为两个品类日销量的经验分位数（即秩），可以直观观察到正向尾部集聚（右上角和左下角的点密度高于均匀 Copula 预期）以及负向尾部结构（茄类-食用菌散点中右下/左上角的稀疏性）。

如图 5 所示，基于 15 组配对拟合的 Kendall τ 矩阵热力图展示了所有配对的相关强度。AIC 准则的拟合结果显示，Student-tCopula 在全部 15 组配对中均优于 Gaussian Copula 和 Clayton Copula，这表明蔬菜品类间的联合分布具有显著的对称厚尾结构，极端需求的同步发生概率高于正态 Copula 的预测。

品类间 Copula 尾部依赖分析




图 5 品类间 Copula 尾部依赖分析

表 4 最优 Copula 拟合结果 (全 15 组品类配对, 按 τ 绝对值降序)

品类对	最优 Copula	Kendall τ	依赖方向
花叶类-花菜类	Student-t	0.457	强正向
水生根茎类-食用菌	Student-t	0.435	强正向
花叶类-辣椒类	Student-t	0.428	强正向
花叶类-食用菌	Student-t	0.427	强正向
辣椒类-食用菌	Student-t	0.393	中等正向
花菜类-食用菌	Student-t	0.326	中等正向
水生根茎类-花叶类	Student-t	0.310	中等正向
辣椒类-花菜类	Student-t	0.306	中等正向
水生根茎类-花菜类	Student-t	0.278	弱正向
水生根茎类-辣椒类	Student-t	0.241	弱正向
花叶类-茄类	Student-t	0.204	弱正向
花菜类-茄类	Student-t	0.145	弱正向
茄类-辣椒类	Student-t	0.094	极弱正向
茄类-食用菌	Student-t	-0.058	极弱负向
水生根茎类-茄类	Student-t	-0.120	弱负向

表 4 汇总了 15 组品类配对的 Copula 拟合结果，所有配对均以 Student-tCopula 取得最优 AIC。花叶类与花菜类之间的 Kendall 秩相关系数最高($\tau=0.457$)，是 15 组配对中需求联动最强的组合；水生根茎类与食用菌($\tau=0.435$)、花叶类与辣椒类($\tau=0.428$) 紧随其后。茄类与食用菌($\tau=-0.058$) 以及水生根茎类与茄类($\tau=-0.120$) 呈现弱负向依赖，暗示在极端需求情景下两者存在一定程度的替代关系。上述结论直接指导了后续 MILP 模型中品类覆盖约束的设计。

4.1.4 Granger 因果网络与互信息分析

Copula 分析揭示了品类间的静态依赖结构，但未回答一个关键问题：品类间的销量变化是否存在时间上的先导-滞后关系？为此，本文进一步采用 Granger 因果检验构建品类间的因果网络。

Granger 因果检验的基本思想是：如果在包含了品类 i 的历史销量信息后，对品类 j 销量的预测精度显著提升（即预测误差方差显著减小），则称品类 i Granger 导致品类 j 。具体而言，对于品类 j 的销量序列 $y_j(t)$ ，比较以下两个 VAR 模型：

受限模型：

$$Y_j(t) = \sum_{k=1}^p \beta_k Y_j(t-k) + \epsilon_t \quad (5)$$

无限制模型：

$$Y_j(t) = \sum_{k=1}^p \beta_k Y_j(t-k) + \sum_{k=1}^p \gamma_k Y_i(t-k) + \eta_t \quad (6)$$

通过 F 检验或 Wald 检验判断 γ_k 是否联合显著异于零。本文对所有 30 组有向品类配对（ $6 \times 5 = 30$ ）进行检验，滞后阶数通过 BIC 准则选择。

表 5 Granger 因果检验结果（显著性水平 $\alpha=0.05$ ）

检验指标数值
总配对数 30
显著配对数 25
显著比例 86.7%
双向因果对数 11
单向因果对数 3

表 5 的结果显示，30 组有向配对中有 26 组存在显著的 Granger 因果关系（ $p < 0.05$ ），显著比例高达 86.7%。这意味着蔬菜品类间存在密集的信息传递网络，某一品类的需求异动可以作为其他品类需求变化的先行指标。

如图 6 所示，对各品类对数差分序列两两做 Granger 因果检验（最大滞后 3 阶），在 30 组有向配对中有 26 组在 5% 水平显著（占 86.7%），构成图 7 的因果网络。该网络近乎全连接：花叶类、辣椒类、食用菌、花菜类、水生根茎类五个品类的出度均为 5，即各自的销量变化都对其余全部品类有显著领先作用，彼此互为领先变量，反映出生鲜需求受共同因素（季节、天气、客流）驱动而高度协同。具有方向性差异的是茄类：其出度仅为 1、入度高达 5，其销量被其余品类的变化带动，却几乎不领先任何品类。出度高的品类可作为整体需求的领先指示，而对茄类则更适合参照其他类的走势被动跟随式补货。




图 6 品类间 Granger 因果网络（显著有向边 26 条）

为了从非线性视角补充 Granger 因果检验的线性因果发现，本文还计算了品类间的互信息（Mutual Information, MI）矩阵。互信息度量两个随机变量之间的总体依赖程度（包括线性和非线性依赖），定义为：

$$MI(X,Y)=\sum_{x\in X}\sum_{y\in Y}p(x,y)\log\frac{p(x,y)}{p(x)p(y)} \quad (7)$$

如图 7 所示，互信息分析与 Copula、Granger 因果检验在“强耦合配对集合”上结论一致：三者均识别出以花叶类为枢纽的叶菜簇（花叶类-辣椒类、花叶类-食用菌、花叶类-花菜类）以及“食用菌-水生根茎类”这一稳定强关联（该配对在 Kendall- τ 与互信息中均列第二）。但二者在“首位配对”的名次上存在差异——Kendall- τ 以花叶类-花菜类

居首，互信息以花叶类-辣椒类居首。其根本原因在于：Kendall- τ 度量的是有符号的单调秩相关，而互信息度量的是包含非线性的总体依赖且无符号；加之上述配对的相关强度高度接近（落入估计误差范围内），故近似并列配对的名次出现翻转属正常现象，不能简单称二者“完全一致”。

品类间互信息与线性相关对比




图 7 品类间互信息热力图

4.1.5 单品销量分布规律与相互关系

品类级分析揭示了宏观结构，但商超的补货与定价最终落到单品。本节进一步分析 246 个有销售记录单品的销量分布规律与单品间相互关系。

(1) 分布规律：长尾与帕累托集中度。单品三年累计销量呈典型的右偏长尾分布：取对数后近似服从对数正态（图 10 左），中位累计销量仅约 257kg，而头部单品高达上万千克。以洛伦兹曲线刻画集中度（图 9 左），基尼系数高达 0.793，销量前 20% 的单品贡献了全部销量的 84.4%（图 9 右的帕累托图亦显示累计曲线在前约 40 个单品即逼近 80% 线），销量前 10 个单品占比即达 39.1%。这种“少数爆款、长尾众多”的结构意味着补货应聚焦高周转头部单品，并为问题三“在有限品种数下选品”提供了直接依据。

单品销量分布的长尾与集中度特征




图 8 单品销量集中度：洛伦兹曲线与前 40 单品帕累托图 (Gini=0.793)

单品销量分布规律与热销单品




图 9 单品累计销量的对数正态分布与累计销量前 20 单品（按品类着色）

(2) 类内异质性。各品类内部单品的销量波动差异显著：以单品日销量变异系数中位数衡量，茄类 (1.03)、水生根茎类 (0.79) 类内单品波动最剧烈，花菜类 (0.59) 相对稳定，说明波动性不仅存在于品类之间，也存在于同品类不同单品之间，单级建模十分必要。

(3) 单品间相互关系。对销量前 25 的热销单品计算 Spearman 秩相关并作层次聚类 (图 10)。相关热力图呈现明显的分块结构：以“云南生菜、云南油麦菜、上海青、奶白菜、青梗散花”等为代表的叶菜类单品高度正相关（最强单品对相关系数达 0.93），常被消费者同篮购买、需求协同上行；而“西兰花、净藕、西峡香菇”等自成一簇，与叶菜簇相关性弱甚至为负。层次聚类将热销单品划分为若干需求模式相近的组团，这一单品级关联结构与前述品类级 Copula/Granger 结论相互印证，可用于关联补货与组合定价（簇内单品协同备货、避免同质单品重复占用陈列）。

单品间销量相互关系：相关结构与聚类




图 10 热销单品间销量相互关系：Spearman 相关热力图与层次聚类

多尺度依赖分析揭示了三个对后续优化具有直接指导意义的关键发现：

- (1) 残差方差占比 33%–44%，证明蔬菜需求具有显著的不可预测随机成分，这是采用随机优化（报童模型）而非确定性 EOQ 的核心依据；
- (2) 2SLS 工具变量分析发现 OLS 存在系统性内生性偏误，驱动了第 4.2.1 节采用批发价格作为工具变量修正弹性估计；
- (3) 品类间存在 26/30 对显著 Granger 因果关系，为协同补货提供了信息共享依据。正是基于上述发现，第 4.2 节才能在正确识别价格弹性和需求分布的基础上，构建有效的联合定价-库存优化框架。

4.2 联合定价-库存随机优化模型（问题二）

【承上启下】问题一从数据层面刻画了蔬菜需求的多尺度结构与品类间依赖关系，但其本质是描述性、诊断性的——它揭示了需求的随机性、季节性以及价格与需求的联动，却尚未据此做出任何定价与补货决策，也未处理“价格与需求相互决定”这一同时性内生复杂度。换言之，问题一回答了“需求长什么样”，却回避了“在需求随机且价格内生的条件下究竟应如何定价与补货”。问题二正是为弥补这一缺口而提出：它把问题一识别出的需求不确定性与价格弹性显式纳入决策，先以批发价格为工具变量、用 2SLS 校正价格内生性，再在含加价率约束的报童框架下联立优化定价与订货量，从而把“对需求的认识”转化为“可执行的品类级最优决策”。

模型选择依据：报童模型的核心优势在于：（1）将随机需求的超买（损耗）和欠买（缺货）损失显式纳入目标函数；（2）通过临界比率公式（ $Q^* = F_D^{-1}\left(\frac{p-c}{p}\right)$ ）提供直观且可解析的最优补货量；（3）可与幂律弹性需求函数联立，推导出联合最优（ p^*, Q^* ）的封闭解。这使得报童模型成为生鲜蔬菜联合定价-库存问题的标准分析框架^{[4][5]}。

4.2.1 工具变量法与价格弹性估计

在蔬菜零售市场中，价格与需求量之间的因果关系并非单向的^[6]：一方面，提高价格会抑制需求（需求定律）；另一方面，当需求增加时，超市可能提高价格以获取更高利润（定价决策的内生响应）。因此本文采用两阶段最小二乘法（2SLS），以批发价格 $c_i(t)$ 作为零售价格 $p_i(t)$ 的工具变量。批发价格满足作为有效工具变量的两个核心条件：（1）相关性条件——批发价格通过成本加成机制直接影响零售价格，两者高度相关；（2）排斥性条件——批发价格由上游批发市场的供需决定，外生于本超市的终端需求冲击。2SLS 的第一阶段将零售价格对批发价格和控制变量进行回归：

$$p_i(t)=\gamma_0+\gamma_1 c_i(t)+\gamma_2 Trend(t)+\gamma_3 Season(t)+v_i(t) \tag{8}$$

第二阶段将需求量对预测的零售价格进行回归，以消除内生性偏差：

$$\ln D_i(t)=\beta_0+\epsilon_i \ln \hat{p}_i(t)+\beta_2 Trend(t)+\beta_3 Season(t)+u_i(t) \tag{9}$$

其中 ϵ_i 为品类 i 的价格弹性系数，在对数-对数模型设定下具有恒定弹性的解释——零售价格每上升 1%，需求量相应变化 $\epsilon_i\%$ 。

本文采用 2SLS 法估计六大品类的价格弹性，估计结果汇总于图 11 和表 6。




图 11 六大品类 2SLS 价格弹性估计结果

表 6 六大品类 2SLS 价格弹性估计结果

品类	2SLS 弹性 ϵ_i	Hausman 检验 p 值	一阶段 F 统计量
花叶类	-0.359	0.000	>600
辣椒类	-0.373	0.000	>600
食用菌	-1.164	0.000	>600
花菜类	-0.568	0.000	>600
茄类	-0.535	0.000	>600

水生根茎类	-1.882	0.000	>600
-------	--------	-------	------

表 6 的结果呈现两点关键结论。第一，所有品类的第一阶段 F 统计量均超过 600，远高于弱工具变量检验经验临界值 10，证实批发价格是强有力的工具变量，内生性修正有效（Hausman 检验 $p=0$ ）。第二，弹性估计将六个品类分为两大类别：水生根茎类（ $\epsilon=-1.882$ ）和食用菌（ $\epsilon=-1.164$ ）属于弹性需求品类，定价时应审慎，过高定价将导致总收入下降；花叶类（ $\epsilon=-0.359$ ）和辣椒类（ $\epsilon=-0.373$ ）属于高度非弹性需求品类，价格敏感度最低，这与其作为日常烹饪基础食材的刚性需求特征一致；花菜类（ $\epsilon=-0.568$ ）和茄类（ $\epsilon=-0.535$ ）处于中间弹性区间。上述弹性参数将直接代入第 4.2.2 节的报童模型，作为联合定价与补货优化的核心输入。

4.2.2 含加价率约束的报童模型

获得无偏的价格弹性估计后，本文将定价决策与库存决策纳入报童模型（Newsvendor Model）的统一框架。经典报童模型假设决策者面临单期库存决策：在需求不确定的情况下，决定最优订货量以最大化期望利润（或最小化期望成本）。本文在此基础上引入两个重要扩展：第一，将定价作为与订货量同时优化的决策变量，使得需求分布通过弹性函数依赖于价格。第二，引入加价率下限约束，超市对最低利润率的经营要求。

设品类 i 在某一天的零售价格为 p_i ，补货量为 Q_i ，批发成本为 c_i ，损耗率为 α_i 。需求 D_i 为随机变量，其分布通过价格弹性函数依赖于 p_i 。本文假设需求的均值函数为恒定弹性形式：

$$E[D_i | p_i] = A_i \cdot p_i^{\epsilon_i} \quad (10)$$

其中 A_i 为品类 i 的需求规模参数（由历史数据标定）， ϵ_i 为 2SLS 估计的价格弹性。进一步假设需求围绕均值函数呈对数正态分布，即

$$\mu_i(p_i) = \ln(A_i \cdot p_i^{\epsilon_i}) - \sigma_i^2 / 2 \quad (11)$$

品类 i 的单日期望利润函数为：

$$\pi_i(p_i, Q_i) = p_i \cdot E[\min(D_i, Q_i)] - c_i \cdot Q_i - \alpha_i \cdot c_i \cdot E[\max(Q_i - D_i, 0)] \quad (12)$$

其中第一项为期望销售收入，第二项为采购成本，第三项为损耗成本。利用分部积分，上式可改写为：

$$\pi_i(p_i, Q_i) = p_i \left[Q_i - \int_0^{Q_i} F_{D_i}(x) dx \right] - c_i Q_i - \alpha_i c_i \int_0^{Q_i} F_{D_i}(x) dx \quad (13)$$

联合优化问题形式化为：

$$\max_{p_i, Q_i} \pi_i(p_i, Q_i) \quad (14)$$

$$\text{s.t. } \frac{p_i - c_i}{c_i} \geq r_{\min} \quad (15)$$

$$p_i > 0, Q_i \geq 0 \quad (16)$$

其中 $r_{\min}$ 为最低加价率约束。

对上述优化问题应用 KKT 条件，可得到最优解的必要条件。对 Q_i 求导并令其为零：

$$\frac{\partial \pi_i}{\partial Q_i} = p_i [1 - F_{D_i}(Q_i^*)] - c_i - \alpha_i c_i F_{D_i}(Q_i^*) = 0 \quad (17)$$

整理得到最优补货量的临界分位数条件：

$$F_{D_i}(Q_i^*) = \frac{p_i - c_i}{p_i + \alpha_i c_i} \quad (18)$$

上式即为修正后的报童临界比率公式。在经典报童模型中（无损耗时），临界比率为 $(p - c)/p$ ，即边际利润与边际收入之比。在本文的模型中，分母增加了“ $\alpha_i c_i$ ”项，反映了过量库存不仅丧失了已支付的采购成本，还需承担额外的损耗处理成本。因此，损耗率的存在会系统性地降低最优临界比率，从而减少最优补货量——这与实际运营中对高损耗品类采取保守补货策略的直觉一致。

对 p_i 的最优性条件则需要利用需求分布对价格的依赖关系。将 $E[\min(D_i, Q_i)]$ 对 p_i 求导，利用恒定弹性需求函数的性质，可以将最优定价与最优补货量联立求解。由于对数正态分布的累积分布函数不存在解析逆，本文采用数值迭代方法求解联立方程组：固定 p_i ，由临界分位数条件求出 Q_i^* ；然后固定 Q_i^* ，通过一维搜索更新 p_i ；交替迭代直至收敛。如图 12 所示，SARIMAX 模型为报童模型提供了未来七天各品类需求分布的预测参数。




图 12 SARIMAX 七日需求预测结果

表 7 SARIMAX 预测精度评估

品类	MAPE(%)	RMSE(kg)
辣椒类	21.2	22.9
花叶类	45.3	60.2
食用菌	38.3	21.4
花菜类	49.0	8.0
水生根茎类	43.6	9.1
茄类	77.9	11.6

表 7 的 SARIMAX 预测精度评估显示，辣椒类的预测精度最高（MAPE=21.2%），而茄类最低（MAPE=77.9%）。预测精度的差异直接影响报童模型的解质量：高 MAPE 品类的最优补货量对需求分布参数更加敏感，需要更大的安全裕度来对冲预测误差。

如图 13 所示，报童模型的最优解在利润曲面上的位置直观展示了各品类的最优定价与订货量组合。

各品类报童模型期望利润曲线与最优补货量




图 13 各品类报童模型最优解

表 8 各品类报童模型最优定价与补货方案

品类	最优价格 p^* (元/kg)	最优补货量	期望利润 $E[\pi]$ (元/天)
花叶类	19.36	133.67	1190.51
辣椒类	31.04	72.47	930.08
花菜类	43.50	15.03	222.24
茄类	24.93	22.63	196.56
水生根茎类	18.11	10.54	27.76
食用菌	14.00	25.16	49.96
合计		279.50	2617.11

表 8 汇总了六大品类的最优定价与补货方案。花叶类以其最大的需求规模 贡献了最高的日均期望利润（1190.51 元），占总期望利润的 45.5%，说明花叶类是超市蔬菜经营的利润支柱。辣椒类紧随其后（930.08 元，占 35.5%），两者合计贡献了总利润的 81%。与之形成对比的是，水生根茎类虽然品种丰富，但由于其高弹性需求($\epsilon=-1.882$) 和高波动性（ $CV=0.848$ ），最优策略是保守定价和低库存水平，日均期望利润仅为 27.76 元。

从定价策略来看，花菜类的最优价格最高（43.50 元/kg），反映了其较低的弹性和较高的批发成本。食用菌的最优价格最低（14.00 元/kg），这是因为其弹性较大($\epsilon=-1.164$)，超市需要通过低价策略刺激需求量以弥补单位利润的不足。

如图 14 所示，以花叶类为代表示例（其他品类的形态类似），联合优化曲面在三维空间（价格轴、补货量轴、期望利润轴）中展示了利润函数关于(p,Q)的交互效应。曲面最高点即为花叶类的最优解（ $p^*=19.36$ 元/kg， $Q^*=133.67$ kg， $E[\pi^*]=1190.51$ 元/天），与表 8 第一行数据完全对应。从曲面形态可以看出：期望利润函数关于(p,Q)是一个严格凹函数，存在唯一的全局最优点；价格过低或过高均会导致利润显著下降，而补货量对利润的敏感度低于价格。




图 14 联合定价-补货优化曲面（以花叶类为代表示例， $p^*=19.36$ 元/kg， $Q^*=133.67$ kg）

表 9 七日逐日定价与补货计划（品类汇总）

日期	总补货量(kg)	总期望利润(元)
7月1日	276.8	2589.5
7月2日	281.2	2642.3
7月3日	283.5	2658.7
7月4日	278.6	2601.4
7月5日	272.3	2548.9

7月6日	285.7	2670.8
7月7日	278.4	2608.2

表9展示了2023年7月1日至7日的逐日品类汇总补货与利润计划。七日总期望利润为18,319.8元，日均约2617元。从时序演化来看，七日预测期内各品类的最优定价保持高度稳定，日间波动幅度不超过3%，这与蔬菜品类的批发价格在短期内相对平稳的实际情况一致。补货量的日间波动略大（约5%-8%），主要受周效应驱动——STL分解揭示的7天季节周期在此处得到了直接应用。本模型的定价策略是“日度动态定价”，即允许零售价格逐日调整以适应批发成本和需求预测的变化，而非简单的固定加价模式。这种动态定价策略相较于传统的固定加价策略，可使七日总利润提升约6%-10%。

4.2.3 鲁棒性分析

为了检验最优解对需求分布参数不确定性的鲁棒性，本文进行了分布鲁棒优化（Distributionally Robust Optimization, DRO）对比分析。具体而言，构建以 Wasserstein 距离为度量的模糊集：

$$P_{\epsilon} = \{P: W_1(P, \hat{P}) \leq \epsilon\} \quad (19)$$

其中 P 为从历史数据估计的经验分布， E 为模糊半径参数。DRO 模型在模糊集中求最坏情况下的最优决策：

$$\max_{p_i, Q_i} \min_{P \in P_{\epsilon}} E_P[\pi_i(p_i, Q_i)] \quad (20)$$

如图15示，以六大品类为对象，对比风险中性基准模型（ $E=0$ ，即第4.2.2节的报童最优解）与鲁棒优化模型（ $E=0.1$ ）的补货量和期望利润。图15中每组柱状图对应一个品类，左柱为基准模型结果，右柱为鲁棒模型结果。当引入鲁棒约束后，各品类最优补货量平均下降约8%-15%，期望利润略有降低（约3%-7%），但极端损耗风险显著降低。对于高波动品类（如水生根茎类， $CV=0.848$ ），鲁棒模型的补货量下降幅度最大，体现了“高不确定性→更保守补货”的内在逻辑。




图 15 六大品类鲁棒优化与风险中性基准模型对比 (补货量与期望利润)

第 4.2 节得到的品类级价格弹性为各单品的定价提供了先验参数，品类级报童结果为各单品补货量的量级提供了参考基准，从而使第 4.3 节的 MILP 模型得以以品类参数为起点进行单品级的精细化求解。

4.3 混合整数规划品种选择-补货-定价优化模型

【承上启下】问题二在品类层面求得了最优定价与补货，但它将每个品类视为同质整体，隐含假设“品类内所有单品可由一条聚合需求曲线代表”，因而无法回答“在有限货架与品种名额下究竟应选哪些单品上架”这一离散选品问题——而问题一的单品级分析已表明品类内部存在显著异质性（销量长尾集中、类内变异系数差异大）。问题二的连续优化框架无法表达这种“选或不选”的组合复杂度，也无法施加品种数量与最小陈列量约束。问题三正是为解决这一被问题二忽略的离散选品复杂性而提出：它把品种选择建模为 0-1 决策，与补货量、定价耦合为混合整数线性规划，在品类全覆盖与陈列量约束下求全局最优，实现从品类级到单品级的精细化落地。

模型选择依据：为何用 MILP 而非贪心算法或遗传算法？

(1) 最优性保证——MILP 通过分支定界法可在多项式时间内找到有理论最优性保障的解（在本例中 49 种单品规模，求解时间约 12 秒）；

(2) 约束处理能力品种数量约束 ($27 \leq \sum y_j \leq 33$)、最小陈列量约束和品类覆盖约束均可被线性化嵌入 MILP 框架，不需要约束罚函数的启发式调整；

(3) 影子价格——MILP 的线性规划松弛提供约束的影子价格，直接量化“增加一个品种名额”或“放宽最小陈列量”的边际价值，为管理决策提供可解释的经济分析。

4.3.1 问题描述与模型构建

问题三要求将决策粒度从品类层面细化到单品层面，在 49 种可选单品中选择 27 至 33 种，同时确定每种被选单品的补货量和定价策略。这是一个典型的联合品种选择与库存优化问题，其核心难点在于品种选择决策（离散）与补货定价决策（连续）之间的耦合，需要采用混合整数规划（Mixed-Integer Linear Programming, MILP）方法求解。

设 $y_j \in \{0,1\}$ 为第 j 种单品的选择决策变量， $Q_j \geq 0$ 为其补货量， $p_j > 0$ 为其零售价格。品种选择-补货-定价联合优化模型的数学表述为：

$$\max_{y_j, Q_j, p_j} \sum_{j=1}^{49} y_j \cdot E[\pi_j(p_j, Q_j)] \quad (21)$$

$$27 \leq \sum_{j=1}^{49} y_j \leq 33 \quad (22)$$

$$Q_j \geq 2.5 \cdot y_j, \quad \forall j=1, \dots, 49 \quad (23)$$

$$Q_j \leq M \cdot y_j, \quad \forall j=1, \dots, 49 \quad (24)$$

$$\sum_{j \in C_i} y_j \geq 1, \quad \forall i=1, \dots, 6 \quad (25)$$

$$\frac{p_j - c_j}{c_j} \geq r_{\min}, \quad \forall j \quad (26)$$

$$y_j \in \{0,1\}, Q_j \geq 0, p_j > 0 \quad (27)$$

其中，第一组约束限定选择的品种数量在 27 至 33 之间；第二组约束确保被选品种的陈列量不低于 2.5 千克；第三组为大 M 约束，将未被选品种的补货量强制为零；第四组约束确保每个品类至少有一种单品被选中，以保证品类的完整覆盖；第五组约束为加价率下限。

4.3.2 期望利润的线性化近似

上述模型的目标函数中， $E[\pi_j(p_j, Q_j)]$ 是关于 (p_j, Q_j) 的非线性函数，包含对数正态分布的积分项，导致整体问题为 MINLP（混合整数非线性规划），直接求解计算复杂度极高。为了使其可由商业求解器高效处理，本文采用分段线性化方法对期望利润函数进行近似。

具体而言，对于每种单品 j ，在其可行定价区间 $[p_j^{\min}, p_j^{\max}]$ 和可行补货量区间 $[2.5, Q_j^{\max}]$ 上选取网格点，计算各网格点处的期望利润值，然后用分段线性函数进行逼近。通过引入辅助的 SOS2（Special Ordered Set of type 2）变量，将分段线性函数嵌入 MILP 框架中。这一线性化

方法的近似误差通过控制网格密度来保证，在本文的计算中，网格密度为每维 20 个点，近似误差不超过目标函数值的 0.5%。

4.3.3 求解结果与分析

图 16 MILP 最优品种选择方案

利用 PuLP 调用 CBC 求解器对上述 MILP 模型进行求解，如图 16 所示，MILP 的最优品种选择方案从 49 种可选单品中选出了 30 种。

表 10 MILP 最优方案汇总指标

指标	数值
选中单品数	30
总补货量	222.6kg
总期望利润	296.4 元
品类覆盖	6/6 (100%)
最小单品补货量	2.5kg
求解时间	≈12s

表 11 各入选单品补货量与定价策略明

单品名称	品类	最优补货量(kg)	最优定价(元/kg)	期望利润(元)
云南生菜(份)	花叶类	15.05	4.46	4.32
小米椒(份)	辣椒类	22.68	5.77	60.89
云南油麦菜(份)	花叶类	17.92	4.16	14.73
金针菇(盒)	食用菌	9.23	1.88	1.63
芜湖青椒(1)	辣椒类	12.78	5.20	17.74
竹叶菜	花叶类	12.15	3.77	11.28
西兰花	花菜类	10.08	12.41	22.62
螺丝椒(份)	辣椒类	8.91	4.92	8.88
小皱皮(份)	辣椒类	10.00	2.59	6.94
紫茄子(2)	茄类	8.48	6.00	9.66
娃娃菜	花叶类	5.36	6.54	2.67
双孢菇(盒)	食用菌	8.68	5.03	10.03
苋菜	花叶类	7.03	3.80	5.39
海鲜菇(包)	食用菌	6.20	2.75	2.56
菠菜(份)	花叶类	6.19	5.51	4.25
姜蒜小米椒组合装	辣椒类	6.52	4.72	9.57
螺丝椒	辣椒类	6.08	11.29	18.49
奶白菜	花叶类	7.21	4.79	12.23
净藕(1)	水生根茎类	4.61	14.40	8.16
木耳菜	花叶类	4.61	5.33	4.77
小青菜(1)	花叶类	4.32	5.20	6.00
西峡花菇(1)	食用菌	3.93	24.00	21.92
红薯尖	花叶类	3.55	5.33	3.78
长线茄	茄类	3.31	12.00	6.29
洪湖藕带	水生根茎类	3.13	24.55	10.78
上海青	花叶类	3.40	8.00	5.82
青茄子(1)	茄类	2.50	6.00	0.43
青红杭椒组合装(份)	辣椒类	2.50	5.49	1.18

菠菜	花叶类	2.50	14.00	0.49
----	-----	------	-------	------

最优方案选中 30 种单品，位于品种数量约束区间（27–33 种）内部，为区间内部最优。总补货量为 222.6 千克，低于品类层面模型的 279.5 千克，这是因为单品层面的优化能够更精准地匹配各单品的需求特征，避免了品类层面聚合带来的“平均化”效应。总期望利润为 296.4 元，反映了单品层面更为精细的优化带来的效率提升。如图 17 所示，通过对偶变量分析，品种数量约束的影子价格（ShadowPrice）揭示了增加一种品种或减少一种品种对总利润的边际影响。影子价格分析表明，在当前最优解附近，由于最优解（30 种）位于品种数量约束区间内部，该数量约束在最优处并不紧（影子价格约为 0）；增加品种的边际利润随品种数递增而递减，约在 30 种附近由正转负——这正是最优品种数落在区间内部（而非上界 33 种）的原因。




图 17 品种数量约束和影子价格分析

4.3.4 灵敏度分析

如图 18 所示，灵敏度分析系统地考察了损耗率与最小陈列量约束这两个关键参数对最优期望利润的联合影响。

首先，从总利润等高线（左图）可以看出，利润对损耗率的变化极其敏感。在固定陈列量的情况下，损耗率倍数从 1.0（基准）上升至 2.0 时，总利润出现断崖式下跌。

其次，最小陈列量约束对盈利能力也存在显著的负向压制作用。观察右侧的灵敏度切面图（红色虚线），当损耗倍数固定为 1.4 时，随着单品最小陈列量要求从 1.0kg 严苛至

5.0kg，总利润呈现出加速下滑的趋势。这是因为过高的强制陈列量，迫使超市违背报童模型的最优订货逻辑，对滞销或高损耗单品进行了过量补货，从而大幅推高了残余废弃成本。




图 18 损耗率与需求方差的灵敏度分析曲面

灵敏度分析的结果对超市的运营管理具有重要启示。首先，降低损耗率（例如通过改进冷链物流或调整陈列方式）的边际经济效益显著——损耗率每降低 1 个百分点，日均利润可提升约 6 元。其次，在需求不确定性较大的季节（如节假日前后），适当提价并减少补货量是最优的风险管理策略。

4.4 数据价值分析（问题四）

【承上启下】问题二与问题三都建立在“需求分布与价格弹性等参数已知且固定”的前提之上，其最优性是以当前信息水平为条件的；它们并未回答一个更高层的问题——这些参数的不确定性本身造成了多大的利润损失，以及为降低该不确定性而投入采购额外数据是否“划算”。也就是说，前序模型把信息质量当作外生给定，忽略了“信息价值”这一复杂度。问题四正是为弥补这一缺口而提出：它以 EVPI（完美信息期望价值）与 EVSI（样本信息期望价值）将“消除或降低需求不确定性”的经济收益显式量化，把数据采购从经验判断转化为成本-收益可比较的投资决策，从而为整个框架补上“要不要、以及优先获取哪类数据”的决策闭环。

本文通过 EVPI（完美信息期望价值）和 EVSI（样本信息期望价值）两个决策理论工具，定量分析不同附加数据源的经济价值，为超市的数据采购决策提供成本收益依据。

4.4.1 完美信息期望价值（EVPI）

在前述模型中，需求的不确定性是制约决策质量的核心因素。如果能够完全消除需求不确定性，决策者的利润是否能提高，因此采用 EVPI（Expected Value of Perfect Information）这个决策理论工具，其定义为：

$$EVPI = E_D \left[\sum_{i=1}^n \pi_i \left(\sum_{j=1}^n p_j \left(D_j \right) \right) - \sum_{j=1}^n p_j \left(D_j \right) \right]$$

其中第一项为“等待并观察”策略下的期望利润——即假设决策者能在观察到真实需求 D 后再做出最优决策；第二项为当前“先决策后观察”策略下的最优期望利润。EVPI 衡量的是需求不确定性造成的期望利润损失上界，也即任何预测系统所能带来的最大经济价值。

表 12 各品类 EVPI 估计值

品类	EVPI (元/天)
花叶类	88.95
辣椒类	66.01
食用菌	40.01
水生根茎类	39.48
花菜类	36.92
茄类	32.38
合计	303.75

表 12 的结果显示，花叶类的 EVPI 最高（88.95 元/天），这与其作为最大销量品类、需求不确定性造成的绝对损失最大密切相关。六大品类的 EVPI 合计为 303.75 元/天，即年化约 110,869 元。这意味着，如果超市能够获得完美的需求预测（例如，通过实时客流监控和精准天气预报的组合），每年最多可提升利润约 11 万元。

4.4.2 样本信息期望价值（EVSI）

EVPI 提供了信息价值的理论上界，但在现实中获得完美信息是不可能的。EVSI（Expected Value of Sample Information）衡量的是引入特定的不完美信息源后，决策质量的预期改善。本文考虑三种潜在的附加数据源：

第一类是精准天气预报数据。蔬菜的供给和需求均受气象条件的显著影响——极端高温会抑制叶菜消费并加速损耗，而降雨天气会减少客流量。通过接入气象局的 72 小时精细化预报数据，超市可以将天气因素纳入需求预测模型，预计可降低预测误差 15%-25%，对应的 EVSI 估计为 EVPI 的 30%-50%。

第二类是实时客流监控数据。通过部署客流计数传感器，超市可以获取每日各时段的到店人数，将其作为需求预测模型的先导指标。客流数据与蔬菜购买行为之间存在强正相关，预计可降低预测误差 10%-20%。

第三类是竞品价格数据。周边竞争性超市或农贸市场的蔬菜价格信息可以帮助优化本店的定价策略，特别是对于弹性较大的品类（如水生根茎类和食用菌），竞品价格是消费者选择购物场所的关键因素。通过构建包含竞品价格变量的扩展需求模型，超市可以实施更具竞争力的差异化定价：对弹性品类实施略低于竞品的定价以吸引客流，同时对非弹性品类维持较高利润率。此外，竞品价格数据还可以帮助超市识别价格领导者和跟随者的角色定位，在局部竞争博弈中做出更优的策略响应。

综合三类附加数据的 EVSI 分析，天气预报数据的信息价值最高（约为 EVPI 的 40%-50%），客流数据次之（约为 EVPI 的 25%-35%），竞品价格数据的直接信息价值相对较小（约为 EVPI 的 10%-15%），但其战略价值在长期定价博弈中不可忽视。考虑到数据采集成本，建议超市优先引入免费或低成本的气象预报数据，再逐步部署客流传感器，最后考虑建立竞品价格监测体系。

如图 19 所示，EVPI 和 EVSI 的对比分析为超市的数据采购决策提供了成本-收益框架。只有当附加数据的年化采购和处理成本低于 EVSI 时，引入该数据才具有经济合理性。




图 19 EVPI 与 EVSI 对比分析

五、模型检验与灵敏度分析

5.1 预测模型诊断

模型的有效性取决于需求预测的准确性和统计假设的合理性。本文从残差诊断和预测精度两个维度对 SARIMAX 模型进行检验。如表 7 所述，SARI-MAX 模型的 MAPE 在 21.2%至 77.9%之间，其中辣椒类和花叶类的预测精度较高，而茄类的预测精度最低。茄类预测困难的主要原因在于其强季节性和高残差方差占比（44%），导致在季节转换期（6-7 月）的需求预测面临较大挑战。

如图 20 所示，残差诊断结果包括残差的自相关函数（ACF）图、偏自相关函数（PACF）图、Q-Q 正态概率图和 Ljung-Box 白噪声检验。六个品类的 SARIMAX 残差未通过白噪声检验（Ljung-Box 检验 $p < 0.001$ ），ACF 和 PACF 在部分滞后阶数上超出 95% 置信带，说明模型已提取了序列中大部分线性可预测信息，但残差仍残留显著自相关与尖峰。Q-Q 图显示残差整体近似正态但存在明显的右侧厚尾特征，进一步支持了本文采用对数正态分布（而非正态分布）建模需求的做法。

花叶类 SARIMAX 模型残差诊断




图 20 SARIMAX 残差诊断

5.2 优化模型的灵敏度检验

如图 19 所述，灵敏度分析系统地考察了关键参数对最优解的影响。除了损耗率和最小陈列量外，本文还对以下参数进行了灵敏度分析：

在加价率约束方面，当最低加价率 r_{min} 从 20% 提升到 50% 时，最优总利润下降约 22%，但各品类的利润排名保持不变，说明模型的品类优先级结构对加价率约束具有结构鲁棒性。在品种数量约束方面，当品种数从 27 增加到 33 时，总利润先增后减，最优拐点出现在 30 种附近，与 MILP 模型的最优解一致。在弹性参数方面，将所有品类的弹性同时在 $\pm 20\%$ 范围内扰动，总利润的变化幅度为 $\pm 11\%$ ，表明模型对弹性估计的不确定性具有合理的鲁棒性。

5.3 交叉验证

为了评估模型的泛化能力，本文采用滚动窗口（RollingWindow）回测法对报童模型进行历史仿真验证。以 2022 年全年的 365 天为测试期，每天基于过去 180 天的数据重新估计需求分布参数和价格弹性，然后利用报童模型生成定价与补货决策，并与实际的销售数据对比。回测结果表明，报童模型的平均日利润比超市实际决策高出约 18%-25%，验证了模型优化带来的显著经济价值。

进一步分析回测结果的时间分布可以发现，模型的优化增益在需求波动较大的月份（如夏季）更为显著，增益可达 30% 以上，而在需求平稳的月份（如秋冬季）增益约为 10%-15%。这一发现符合直觉——在需求不确定性较高的时期，基于数据驱动的随机优化模型相对于经验决策的信息优势更加突出。此外，模型在连续多日的预测准确率均超过 60% 时，累积利润增益呈现加速上升趋势，说明预测精度与优化收益之间存在非线性的正反馈关系，这进一步强调了持续提升需求预测精度的经济重要性。在 MILP 品种选择模型的回测中，模型选出的品种组合在不同季节表现出合理的适应性调整：夏季倾向于增加叶菜和瓜果类单品比例，冬季则增加根茎类和菌类的比重，这种自适应特征源于模型对季节性需求分布参数的动态更新机制。

六、模型的评价与推广

6.1 模型优点

本文所构建的四阶段集成优化框架具有以下优点。第一，多尺度依赖分析模型综合运用 STL 分解、小波变换、Copula 函数和 Granger 因果检验四种互补的分析工具，从不同维度全面刻画了蔬菜品类的需求结构和品类间的依赖关系，为后续优化决策提供了坚实的统计基础。第二，联合定价-库存随机优化模型通过 2SLS 工具变量法解决了价格内生性问题，避免了 OLS 弹性估计的偏差，使得报童模型的定价建议具有因果推断的可靠性。第三，MILP 品种选择模型将离散的品种选择决策与连续的补货定价决策整合到统一的优化框架中，通过分段线性化技术实现了高效求解。第四，EVPI 和 EVSI 框架为超市的数据采购决策提供了定量的经济分析工具，连接了决策理论与运营实践。

6.2 模型不足

本文模型也存在若干局限性。首先，模型假设各品类的定价决策不存在交叉弹性效应，即一个品类的定价不影响其他品类的需求，这一假设在短期内合理但在长期可能导致定价偏差。实际上，蔬菜品类之间存在一定的替代和互补关系，例如当花菜类价格上涨时，部分消费者可能转向购买花叶类作为替代。未来的研究可以引入多品类需求系统模型（如 Almost Ideal Demand System, AIDS）来刻画交叉弹性效应，从而实现跨品类的协同定价优化。其次，模型采用的单期报童框架未考虑多期库存决策的跨期动态效应，如库存积压对次日需求的影响和批量采购的规模经济。在实际运营中，前一天的剩

余库存可以在次日继续销售（虽然品质有所下降），这种跨期传递效应在多期动态规划框架中可以被显式建模，从而避免每日独立决策导致的短视行为。第三，SARIMAX 模型在极端天气或节假日等异常事件的预测能力有限，当遭遇罕见事件（如突发疫情或异常气候）时，历史数据的代表性显著下降，模型预测误差可能急剧放大。未来可以考虑引入深度学习方法（如 LSTM 或 Transformer 时序模型）来增强非线性模式的捕捉能力，或采用贝叶斯在线更新机制实现对异常事件的快速自适应响应。

6.3 推广前景

本文的建模框架具有良好的推广应用前景。在纵向拓展方面，模型可以自然地推广到其他生鲜品类（如水果、肉禽、水产品），只需根据各品类的特定损耗率和需求分布进行参数重标定。在横向拓展方面，联合定价-库存-品种选择的集成优化范式适用于任何面临需求不确定性、产品易腐和品种管理决策的零售场景，如便利店、社区团购和生鲜电商。在技术升级方面，未来可以将实时数据流（如物联网传感器数据和社交媒体情感分析）纳入决策框架，构建自适应的智能定价与补货系统。

参考文献

- [1]吴萌,张驰,王志勇.“蔬菜类商品的自动定价与补货决策”问题解析[J].数学建模其应用,2024,13(2):27-36.DOI:10.19943/j.2095-3070.jmmia.2024.02.04.
- [2]曹宇轩,黄瑞,秦一天.基于历史数据的蔬菜类商品定价与补货决策模型[J].数学建模及其应用,2024,13(2):37-46.DOI:10.19943/j.2095-3070.jmmia.2024.02.05.
- [3]陈妙霞,朱映辉,张赞,等.基于 SARIMA 模型的生鲜类商品自动定价与补货决策——以蔬菜类商品为例[J].数字技术与应用,2024,42(10):147-150.
- [4]PetruzziN C, Dada M. Pricing and the newsvendor problem: A review with extensions[J]. Operations Research, 1999, 47(2):183-194.
- [5]Whitin T M. Inventory control and price theory[J]. Management Science, 1955, 2(1): 61-68.
- [6] Qin Y, Wang R, Vakharia A J, et al. The newsvendor problem: Review and directions for future research[J]. European Journal of Operational Research,2011,213(2):361-374.

附录 A 运行环境要求与复现说明

运行环境要求

本文所有核心代码均采用 Python3 编写，依赖以下主要库：

库名	版本要求	用途
----	------	----

pandas	≥1.3	数据读取与处理
numpy	≥1.20	数值计算
scipy	≥1.7	统计检验、优化求解
matplotlib	≥3.4	可视化图表
scikit-learn	≥0.24	互信息、聚类
statsmodels	≥0.13	SARIMAX 模型、Granger 检验
openpyxl	≥3.0	Excel 数据读取
pulp	≥2.7	MILP 品种选择求解 (CBC)
pywavelets	≥1.4	MODWT 小波多分辨率分析

安装命令：`pip install pandas numpy scipy matplotlib scikit-learn statsmodels openpyxl pulp pywavelets`

文件结构与运行顺序

运行顺序	脚本文件	生成内容
0	preprocess.py	数据预处理与清洗 (生成 processed/ 数据)
1	build_part1.py	问题一：STL/小波/Copula/Granger 多尺度依赖分析
2	build_item.py	问题一：单品级销量分布与相互关系分析
3	build_part2.py	问题二：2SLS 弹性、SARIMAX 预测与报童联合优化
4	build_part3.py	问题三：MILP 品种选择-补货-定价优化
5	build_part4.py	问题四：EVPI/EVSI 信息价值分析与残差诊断
6	build_diagrams.py	全篇思路框架图

运行说明：(1) 将附件 1–4 (xlsx 文件) 放置于代码同级目录或../目录下；
 (2) 从项目根目录执行各脚本，输出图表自动保存至 figures/ 目录，数值结果保存至 tables/ 目录；(3) 所有图表生成代码均采用固定随机种子 (`np.random.seed(42)`)，可完整复现论文中的所有数值结果和图形；
 (4) statsmodels 为 SARIMAX 预测与 Granger 因果检验所必需，pulp 为 MILP

求解所必需，pywavelets 为 MODWT 小波分析所必需，请按上述完整安装命令安装全部依赖后再运行各脚本。

附录 B 核心代码与数据文件清单

本附录列出随论文一并提交的全部核心源代码与数据文件（统一存放于 20260666C/代码与数据 文件夹），并给出复现说明。所有代码均基于 Python 3.11 编写，依赖 NumPy、Pandas、SciPy、Statsmodels、PyWavelets、PuLP、scikit-learn、Matplotlib 与 openpyxl（均已在该环境下测试通过）。各核心代码文件的功能如下：preprocess.py——读取附件 1-4（xlsx），完成列名规范化、退货/打折/异常的标记（仅标记不删除，零删除策略）、品类与损耗率合并，输出 processed/ 目录下的单品主表 item_master.csv、单品×日明细 daily_item.csv、品类×日明细 daily_category.csv 与清洗后逐笔流水 cleaned_transactions.parquet；common.py——统一的数据加载、品类日销量矩阵构建、学术绘图风格与关键参数（含各品类价格弹性等）配置，供其余脚本调用；build_part1.py——问题一多尺度依赖分析（STL 分解、MODWT(db4) 小波多分辨率分析、Student-t Copula 拟合与 Kendall- τ 矩阵、Granger 因果网络与互信息）；build_item.py——问题一单品类分析（长尾分布、洛伦兹曲线与帕累托集中度、类内异质性、热销单品 Spearman 相关与层次聚类）；build_part2.py——问题二联合定价-库存随机优化（2SLS 价格弹性估计、SARIMAX 七日需求预测、含加价率约束的报童模型 KKT 数值求解，以及 Wasserstein 分布鲁棒优化 DRO 的鲁棒性检验）；build_part3.py——问题三 MILP 品种选择-补货-定价（以 PuLP 调用 CBC 求解器、期望利润分段线性化、品种数量约束影子价格与损耗率/陈列量灵敏度分析）；build_part4.py——问题四信息价值分析（EVPI/EVSI）及 SARIMAX 残差诊断；build_diagrams.py——生成全篇思路框架图等示意图。数据文件包括原始附件 1.xlsx-4.xlsx 以及预处理输出的 processed/ 目录。复现步骤：先运行 preprocess.py 生成 processed/ 数据，再依次运行 build_part1.py、build_item.py、build_part2.py、build_part3.py、build_part4.py、build_diagrams.py；全部图表与数值结果将自动写入 figures/ 目录与 stats.json，随机种子固定（np.random.seed(42)）以保证论文中所有数值结果与图形可完整复现。